

Практическое задание №2

Общая терминология по используемым данным

Предоставляемые данные для разработки моделей и алгоритмов трекинга мяча в теннисе представляют собой набор игр (game), состоящих из нескольких клипов (clip), каждый из которых состоит из набора кадров (frame). Обратите внимание на структуру организации файлов внутри предоставляемого датасета для полного понимания.

Большинство алгоритмов трекинга объектов работают с несколькими последовательными кадрами, и в данном задании также подразумевается использование этого приема. Последовательность нескольких кадров будем именовать стопкой (stack), размер стопки (stack_s) является гиперпараметром разрабатываемого алгоритма.

Заготовка решения

Загрузка датасета

Для работы с данными в ноутбуке kaggle необходимо подключить датасет. File -> Add or upload data, далее в поиске написать tennis-tracking-assignment и выбрать датасет. Если поиск не работает, то можно добавить датасет по url: <https://www.kaggle.com/xubiker/tennistackingassignment>. После загрузки данные датасета будут примонтированы в ../input/tennistackingassignment.

Установка и импорт зависимостей

Установка необходимых пакетов (не забудьте "включить интернет" в настройках ноутбука kaggle):

```
In [ ]: !pip install moviepy --upgrade
        !pip install gdown
```

После установки пакетов для корректной работы надо обязательно перезагрузить ядро. Run -> Restart and clear cell outputs. Без сего действия будет ошибка при попытке обращения к библиотеке moviepy при сохранении визуализации в виде видео. Может когда-то авторы библиотеки это починят...

Импорт необходимых зависимостей:

```
In [20]: import os
os.environ['CUDA_LAUNCH_BLOCKING'] = '1'

from pathlib import Path
from typing import List, Tuple, Sequence

import numpy as np
import cv2
from numpy import unravel_index
from PIL import Image, ImageDraw, ImageFont
from tqdm import tqdm, notebook

from moviepy.video.io.ImageSequenceClip import ImageSequenceClip

import math
from scipy.ndimage import gaussian_filter
from scipy.ndimage.measurements import center_of_mass, variance, standard_deviation
from scipy.interpolate import interp1d

import gdown
import matplotlib.pyplot as plt
import gc
import time
import random
import csv
from collections import namedtuple
from math import exp

import keras
import tensorflow as tf
from keras.models import Sequential, Model, load_model
from keras.layers import Input, Activation, UpSampling2D, LeakyReLU, Multiply, Add, Average, Dense,

from keras.losses import binary_crossentropy
from keras.regularizers import l2
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.optimizers.schedules import ExponentialDecay, PiecewiseConstantDecay
```

```
from keras.callbacks import ModelCheckpoint
from keras import backend as K
```

Набор функций для загрузки данных из датасета

Функция `load_clip_data` загружает выбранный клип из выбранной игры и возвращает его в виде numpy массива `[n_frames, height, width, 3]` типа `uint8`. Для ускорения загрузки используется кэширование - однажды загруженные клипы хранятся на диске в виде `npz` архивов, при последующем обращении к таким клипам происходит загрузка `npz` архива.

Также добавлена возможность чтения клипа в половинном разрешении `640x360`, вместо оригинального `1280x720` для упрощения и ускорения разрабатываемых алгоритмов.

Функция `load_clip_labels` загружает референсные координаты мяча в клипе в виде numpy массива `[n_frames, 4]`, где в каждой строке массива содержатся значения `[code, x, y, q]`. `x, y` соответствуют координате центра мяча на кадре, `q` не используется в данном задании, `code` описывает статус мяча:

- `code = 0` - мяча в кадре нет
- `code = 1` - мяч присутствует в кадре и легко идентифицируем
- `code = 2` - мяч присутствует в кадре, но сложно идентифицируем
- `code = 3` - мяч присутствует в кадре, но заслонен другими объектами.

При загрузке в половинном разрешении координаты `x, y` делятся на 2.

Функция `load_clip` загружает выбранный клип и соответствующий массив координат и возвращает их в виде пары.

```
In [2]: def get_num_clips(path: Path, game: int) -> int:
        return len(list((path / f'game{game}/').iterdir()))

def get_game_clip_pairs(path: Path, games: List[int]) -> List[Tuple[int, int]]:
    return [(game, c) for game in games for c in range(1, get_num_clips(path, game) + 1)]

def load_clip_data(path: Path, game: int, clip: int, downscale: bool, quiet=False) -> np.ndarray:
    if not quiet:
        suffix = 'downscaled' if downscale else ''
        print(f'loading clip data (game {game}, clip {clip}) {suffix}')
    cache_path = path / 'cache'
    cache_path.mkdir(exist_ok=True)
    resize_code = '_ds2' if downscale else ''
    cached_data_name = f'{game}_{clip}{resize_code}.npz'
    if (cache_path / cached_data_name).exists():
        clip_data = np.load(cache_path / cached_data_name)['clip_data']
    else:
        clip_path = path / f'game{game}/clip{clip}'
        n_imgs = len(list(clip_path.iterdir())) - 1
        imgs = [None] * n_imgs
        for i in notebook.tqdm(range(n_imgs)):
            img = Image.open(clip_path / f'{i:04d}.jpg')
            if downscale:
                img = img.resize((img.width // 2, img.height // 2),)
            imgs[i] = np.array(img, dtype=np.uint8)
        clip_data = np.stack(imgs)
        cache_path.mkdir(exist_ok=True, parents=True)
        np.savez_compressed(cache_path / cached_data_name, clip_data=clip_data)
    return clip_data

def load_clip_labels(path: Path, game: int, clip: int, downscale: bool, quiet=False):
    if not quiet:
        print(f'loading clip labels (game {game}, clip {clip})')
    clip_path = path / f'game{game}/clip{clip}'
    labels = []
    with open(clip_path / 'labels.csv') as csvfile:
        lines = list(csv.reader(csvfile))
        for line in lines[1:]:
            values = np.array([-1 if i == '' else int(i) for i in line[1:]])
            if downscale:
                values[1] //= 2
                values[2] //= 2
            labels.append(values)
    return np.stack(labels)

def load_clip(path: Path, game: int, clip: int, downscale: bool, quiet=False):
    data = load_clip_data(path, game, clip, downscale, quiet)
    labels = load_clip_labels(path, game, clip, downscale, quiet)
```

```

        return data, labels

In [ ]: data, labels = load_clip(
        Path('../input/tennistackingassignment/train/'),
        game=1, clip=1,
        downscale=True, quiet=True
    )

In [ ]: data.shape, labels.shape

```

Набор дополнительных функций

Еще несколько функций, немного облегчающих выполнение задания:

- `prepare_experiment` создает новую директорию в `out_path` для хранения результатов текущего эксперимента. Нумерация выполняется автоматически, функция возвращает путь к созданной директории эксперимента;
- `ball_gauss_template` - создает "шаблон" мяча, может быть использована в алгоритмах поиска мяча на изображении по корреляции;
- `create_masks` - принимает набор кадров и набор координат мяча, и генерирует набор масок, в которых помещает шаблон мяча на заданные координаты. Может быть использована при обучении нейронной сети семантической сегментации;

```

In [3]: def prepare_experiment(out_path: Path) -> Path:
        out_path.mkdir(parents=True, exist_ok=True)
        dirs = [d for d in out_path.iterdir() if d.is_dir() and d.name.startswith('exp_')]
        experiment_id = max(int(d.name.split('_')[1]) for d in dirs) + 1 if dirs else 1
        exp_path = out_path / f'exp_{experiment_id}'
        exp_path.mkdir()
        return exp_path


def ball_gauss_template(rad, sigma):
    x, y = np.meshgrid(np.linspace(-rad, rad, 2 * rad + 1), np.linspace(-rad, rad, 2 * rad + 1))
    dst = np.sqrt(x * x + y * y)
    gauss = np.exp(-(dst ** 2 / (2.0 * sigma ** 2)))
    return gauss


def create_masks(data: np.ndarray, labels: np.ndarray, resize):
    rad = 64
    sigma = 10
    if resize:
        rad //= 2
    ball = ball_gauss_template(rad, sigma)
    n_frames = data.shape[0]
    sh = rad
    masks = []
    for i in range(n_frames):
        label = labels[i, ...]
        frame = data[i, ...]
        if 0 < label[0] < 3:
            x, y = label[1:3]
            mask = np.zeros((frame.shape[0] + 2 * rad + 2 * sh, frame.shape[1] + 2 * rad + 2 * sh), np
            mask[y + sh : y + sh + 2 * rad + 1, x + sh : x + sh + 2 * rad + 1] = ball
            mask = mask[rad + sh : -rad - sh, rad + sh : -rad - sh]
            masks.append(mask)
        else:
            masks.append(np.zeros((frame.shape[0], frame.shape[1]), dtype=np.float32))
    return np.stack(masks)

In [ ]: masks = create_masks(data, labels, resize=True)
        masks.shape

In [ ]: plt.imshow(masks[0, :, :])
        plt.show()

```

Набор функций, предназначенных для визуализации результатов

Функция `visualize_prediction` принимает набор кадров, набор координат детекции мяча (можно подавать как референсные значения, так и предсказанные) и создает видеоклип, в котором отрисовывается положение мяча, его трек, номер кадра и метрика качества трекинга (если она была передана в функцию). Видеоклип сохраняется в виде mp4 файла. Кроме того данная функция создает текстовый файл, в который записывает координаты детекции мяча и значения метрики качества трекинга.

Функция `visualize_prob` принимает набор кадров и набор предсказанных карт вероятности и создает клип с наложением предсказанных карт вероятности на исходные карты. Области "подсвечиваются" желтым, клип сохраняется в виде mp4 видеофайла. Данная функция может быть полезна при наличии в алгоритме трекинга сети, осуществляющей семантическую сегментацию.

```

def _add_frame_number(frame: np.ndarray, number: int) -> np.ndarray:
    fnt = ImageFont.load_default() # ImageFont.truetype("arial.ttf", 25)
    img = Image.fromarray(frame)
    draw = ImageDraw.Draw(img)
    draw.text((10, 10), f'frame {number}', font=fnt, fill=(255, 0, 255))
    return np.array(img)

def _vis_clip(data: np.ndarray, lbls: np.ndarray, metrics: List[float] = None, ball_rad=5, color=(255, 0,
print('performing clip visualization')
n_frames = data.shape[0]
frames_res = []
fnt = ImageFont.load_default() # ImageFont.truetype("arial.ttf", 25)
for i in range(n_frames):
    img = Image.fromarray(data[i, ...])
    draw = ImageDraw.Draw(img)
    txt = f'frame {i}'
    if metrics is not None:
        txt += f', SiBaTrAcc: {metrics[i]:.3f}'
    draw.text((10, 10), txt, font=fnt, fill=(255, 0, 255))
    label = lbls[i]
    if label[0] != 0: # the ball is clearly visible
        px, py = label[1], label[2]
        draw.ellipse((px - ball_rad, py - ball_rad, px + ball_rad, py + ball_rad), outline=color, wid
        for q in range(track_length):
            if lbls[i-q-1][0] == 0:
                break
            if i - q > 0:
                draw.line((lbls[i - q - 1][1], lbls[i - q - 1][2], lbls[i - q][1], lbls[i - q][2]), fi
    frames_res.append(np.array(img))
return frames_res

def _save_clip(frames: Sequence[np.ndarray], path: Path, fps):
    assert path.suffix in ('.mp4', '.gif')
    clip = ImageSequenceClip(frames, fps=fps)
    if path.suffix == '.mp4':
        clip.write_videofile(str(path), fps=fps, logger=None)
    else:
        clip.write_gif(str(path), fps=fps, logger=None)

def _to_yellow_heatmap(frame: np.ndarray, pred_frame: np.ndarray, alpha=0.4):
    img = Image.fromarray((frame * alpha).astype(np.uint8))
    maskR = (pred_frame * (1 - alpha) * 255).astype(np.uint8)
    maskG = (pred_frame * (1 - alpha) * 255).astype(np.uint8)
    maskB = np.zeros_like(maskG, dtype=np.uint8)
    mask = np.stack([maskR, maskG, maskB], axis=-1)
    return img + mask

def _vis_pred_heatmap(data_full: np.ndarray, pred_prob: np.ndarray, display_frame_number):
    n_frames = data_full.shape[0]
    v_frames = []
    for i in range(n_frames):
        frame = data_full[i, ...]
        pred = pred_prob[i, ...]
        hm = _to_yellow_heatmap(frame, pred)
        if display_frame_number:
            hm = _add_frame_number(hm, i)
        v_frames.append(hm)
    return v_frames

def visualize_prediction(data_full: np.ndarray, labels_pr: np.ndarray, save_path: Path, name: str, metric
    with open(save_path / f'{name}.txt', mode='w') as f:
        if metrics is not None:
            f.write(f'SiBaTrAcc: {metrics[-1]} \n')
        for i in range(labels_pr.shape[0]):
            f.write(f'frame {i}: {labels_pr[i, 0]}, {labels_pr[i, 1]}, {labels_pr[i, 2]} \n')

    v = _vis_clip(data_full, labels_pr, metrics)
    _save_clip(v, save_path / f'{name}.mp4', fps=fps)

def visualize_prob(data: np.ndarray, pred_prob: np.ndarray, save_path: Path, name: str, frame_number=True
    v_pred = _vis_pred_heatmap(data, pred_prob, frame_number)

```

```

_save_clip(v_pred, save_path / f'{name}_prob.mp4', fps=15)
In []: data, labels = load_clip(
    Path('../input/tennistackingassignment/train/'),
    game=1, clip=1,
    downscale=True, quiet=True
)
masks = create_masks(data, labels, resize=True)
visualize_prob(data, masks, save_path=Path("./"), name="test")

```

Класс DataGenerator

Класс, отвечающий за генерацию данных для обучения модели. Принимает на вход путь к директории с играми, индексы игр, используемые для генерации данных, и размер стопки. Хранит в себе автоматически обновляемый пул с клипами игр.

В пуле содержится pool_s клипов. DataGenerator позволяет генерировать батч из стопок (размера stack_s) последовательных кадров. Выбор клипа для извлечения данных взвешенно-случайный: чем больше длина клипа по сравнению с другими клипами в пуле, тем вероятнее, что именно из него будет сгенерирована стопка кадров. Выбор стопки кадров внутри выбранного клипа полностью случаен. Кадры внутри стопки конкатенируются по последнему измерению (каналам).

После генерирования количества кадров равного общему количеству кадров, хранимых в пуле, происходит автоматическое обновление пула: из пула извлекаются pool_update_s случайных клипов, после чего в пул загружается pool_update_s случайных клипов, не присутствующих в пуле. В случае, если размер пула pool_s больше или равен суммарному количеству клипов в играх, переданных в конструктор, все клипы сразу загружаются в пул, и автообновление не производится.

Использование подобного пула позволяет работать с практически произвольным количеством клипов, без необходимости загружать их всех в оперативную память.

Для вашего удобства функция извлечения стопки кадров из пула помимо самой стопки также создает и возвращает набор сгенерированных масок с мячом исходя из референсных координат мяча в клипе.

Функция random_g принимает гиперпараметр размера стопки кадров и предоставляет генератор, возвращающий стопки кадров и соответствующие им маски. Данный генератор может быть использован при реализации решения на tensorflow. Обновление пула происходит автоматически, об этом беспокоиться не нужно.

```

In [5]: class DataGenerator:
    def __init__(
        self,
        path: Path, games: List[int],
        stack_s, downscale,
        pool_s=30, pool_update_s=10,
        pool_autoupdate=True,
        quiet=False
    ) -> None:
        self.path = path
        self.stack_s = stack_s
        self.downscale = downscale
        self.pool_size = pool_s
        self.pool_update_size = pool_update_s
        self.pool_autoupdate = pool_autoupdate
        self.quiet = quiet
        self.data = []
        self.masks = []

        self.frames_in_pool = 0
        self.produced_frames = 0
        self.game_clip_pairs = get_game_clip_pairs(path, list(set(games)))
        self.game_clip_pairs_loaded = []
        self.game_clip_pairs_not_loaded = list.copy(self.game_clip_pairs)
        self.pool = {}

        self._first_load()

    def _first_load(self):
        # --- if all clips can be placed into pool at once, there is no need to refresh pool at all
        if len(self.game_clip_pairs) <= self.pool_size:
            for gcp in self.game_clip_pairs:
                self._load(gcp)
                self.game_clip_pairs_loaded = list.copy(self.game_clip_pairs)
                self.game_clip_pairs_not_loaded.clear()
                self.pool_autoupdate = False
            else:
                self._load_to_pool(self.pool_size)
                self._update_clip_weights()

    def _load(self, game_clip_pair):
        game, clip = game_clip_pair

```

```

data, labels = load_clip(self.path, game, clip, self.downscale, quiet=self.quiet)
masks = create_masks(data, labels, self.downscale)
weight = data.shape[0] if data.shape[0] >= self.stack_s else 0
self.pool[game_clip_pair] = (data, labels, masks, weight)
self.frames_in_pool += data.shape[0] - self.stack_s + 1
# print(f'items in pool: {len(self.pool)} - {self.pool.keys()}')

def _remove(self, game_clip_pair):
    value = self.pool.pop(game_clip_pair)
    self.frames_in_pool -= value[0].shape[0] - self.stack_s + 1
    del value
    # print(f'items in pool: {len(self.pool)} - {self.pool.keys()}')

def _update_clip_weights(self):
    weights = [self.pool[pair][-1] for pair in self.game_clip_pairs_loaded]
    tw = sum(weights)
    self.clip_weights = [w / tw for w in weights]
    # print(f'clip weights: {self.clip_weights}')

def _remove_from_pool(self, n):
    # --- remove n random clips from pool ---
    if len(self.game_clip_pairs_loaded) >= n:
        remove_pairs = random.sample(self.game_clip_pairs_loaded, n)
        for pair in remove_pairs:
            self._remove(pair)
            self.game_clip_pairs_loaded.remove(pair)
            self.game_clip_pairs_not_loaded.append(pair)
        gc.collect()

def _load_to_pool(self, n):
    # --- add n random clips to pool ---
    gc.collect()
    add_pairs = random.sample(self.game_clip_pairs_not_loaded, n)
    for pair in add_pairs:
        self._load(pair)
        self.game_clip_pairs_not_loaded.remove(pair)
        self.game_clip_pairs_loaded.append(pair)

def update_pool(self):
    self._remove_from_pool(self.pool_update_size)
    self._load_to_pool(self.pool_update_size)
    self._update_clip_weights()

def get_random_stack(self):
    pair_idx = np.random.choice(len(self.game_clip_pairs_loaded), 1, p=self.clip_weights)[0]
    game_clip_pair = self.game_clip_pairs_loaded[pair_idx]
    d, _, m, _ = self.pool[game_clip_pair]
    start = np.random.choice(d.shape[0] - self.stack_s, 1)[0]
    frames_stack = d[start : start + self.stack_s, ...]
    frames_stack = np.squeeze(np.split(frames_stack, indices_or_sections=self.stack_s, axis=0))
    frames_stack = np.concatenate(frames_stack, axis=-1)
    mask = m[start + self.stack_s - 1, ...]
    return frames_stack, mask

def get_random_batch(self, batch_s):
    imgs, masks = [], []
    while len(imgs) < batch_s:
        frames_stack, mask = self.get_random_stack()
        imgs.append(frames_stack)
        masks.append(mask)
    if self.pool_autoupdate:
        self.produced_frames += batch_s
        # print(f'produced frames: {self.produced_frames} from {self.frames_in_pool}')
        if self.produced_frames >= self.frames_in_pool:
            self.update_pool()
            self.produced_frames = 0
    return np.stack(imgs), np.stack(masks)

def random_g(self, batch_s):
    while True:
        imgs_batch, masks_batch = self.get_random_batch(batch_s)
        yield imgs_batch, masks_batch

```

Пример использования DataGenerator

Рекомендованный размер пула pool_s=10 в случае использования уменьшенных вдвое изображений. При большем размере пула есть большая вероятность нехватки имеющихся 13G оперативной памяти. Используйте параметр quiet=True в конструкторе DataGenerator, если хотите скрыть все сообщения о чтении данных и обновлении пула.

```
In[: stack_s = 3
      batch_s = 4
      train_gen = DataGenerator(
          Path('../input/tennistackingassignment/train/'),
          games=[1, 2, 3, 4],
          stack_s=stack_s,
          downscale=True,
          pool_s=10, pool_update_s=4,
          quiet=True
      )

In[: for i in range(10):
      imgs, masks = train_gen.get_random_batch(batch_s)
      print(imgs.shape, imgs.dtype, masks.shape, masks.dtype)

In[: train_gen = DataGenerator(
      Path('../input/tennistackingassignment/train/'),
      games=[1],
      stack_s=stack_s,
      downscale=True,
      pool_s=10,
      pool_update_s=4,
      quiet=True
  )

In[: stack, mask = train_gen.get_random_stack()
      for i in range(stack_s):
          plt.figure()
          plt.imshow(stack[:, :, 3 * i: 3 * i + 3])

          plt.imshow(stack[:, :, 0] + mask * 255)
```

Класс Metrics

Класс для вычисления метрики качества трекинга SiBaTrAcc. Функция evaluate_predictions принимает массив из референсных и предсказанных координат мяча для клипа и возвращает массив аккумулированных значений SiBaTrAcc (может быть полезно для визуализации результатов предсказания) и итоговое значение метрики SiBaTrAcc.

```
In [6]: class Metrics:

        @staticmethod
        def position_error(label_gt: np.ndarray, label_pr: np.ndarray, step=8, alpha=1.5, e1=5, e2=5):
            # gt codes:
            # 0 - the ball is not within the image
            # 1 - the ball can easily be identified
            # 2 - the ball is in the frame, but is not easy to identify
            # 3 - the ball is occluded
            if label_gt[0] != 0 and label_pr[0] == 0:
                return e1
            if label_gt[0] == 0 and label_pr[0] != 0:
                return e2
            dist = math.sqrt((label_gt[1] - label_pr[1]) ** 2 + (label_gt[2] - label_pr[2]) ** 2)
            pe = math.floor(dist / step) ** alpha
            pe = min(pe, 5)
            return pe

        @staticmethod
        def evaluate_predictions(labels_gt, labels_pr) -> Tuple[List[float], float]:
            pe = [Metrics.position_error(labels_gt[i, ...], labels_pr[i, ...]) for i in range(len(labels_
            SIBATRACC = []
            for i, _ in enumerate(pe):
                SIBATRACC.append(1 - sum(pe[: i + 1]) / ((i + 1) * 5))
            SIBATRACC_total = 1 - sum(pe) / (len(labels_gt) * 5)
            return SIBATRACC, SIBATRACC_total
```

Основной класс модели SuperTrackingModel

Реализует всю логику обучения, сохранения, загрузки и тестирования разработанной модели трекинга. Этот класс можно и нужно расширять.

В качестве примера вам предлагается заготовка модели, в которой трекинг осуществляется за счет предсказания маски по входному батчу и последующему предсказанию координат мяча по полученной маске. В данном варианте вызов функции предсказания координат по клипу (predict) повлечет за собой разбиение клипа на батчи, вызов предсказания маски для каждого батча, склеивание результатов в последовательность масок, вызов функции по вычислению координат мяча по маскам и возвращения результата. Описанные действия уже реализованы, вам остается только написать функции predict_on_batch и get_labels_from_prediction. Эта же функция predict используется и в вызове функции test, дополнительно вычисляя метрику качества трекинга и при необходимости визуализируя результат тестирования. Обратите внимание, что в результирующем numpy массиве с координатами помимо значений x и y первым значением в каждой строке должно идти значение code (0, если мяча в кадре нет и > 0, если мяч в кадре есть) для корректного вычисления качества трекинга.

Вам разрешается менять логику работы класса модели, (например, если решение не подразумевает использование масок), но при этом логика и работа функций load и test должна остаться неизменной!

```
In [21]: # g = upsample, x = block_i_out, inter_channel = down_layer_channels // 4
def attention_block(x, g, inter_channel):
    theta_x = Conv2D(inter_channel, (1, 1), strides=(1, 1), padding="same")(x)
    phi_g = Conv2D(inter_channel, (1, 1), strides=(1, 1), padding="same")(g)
    f = Activation("relu")(Add()([theta_x, phi_g]))
    psi_f = Conv2D(1, (1, 1), strides=(1, 1), padding="same")(f)
    rate = Activation("sigmoid")(psi_f)
    att_x = Multiply()([x, rate])
    return att_x

def cba_block(inputs, filters):
    x = Conv2D(filters, (3, 3), kernel_initializer="he_uniform", padding="same")(inputs)
    x = BatchNormalization(fused=True, dtype=tf.float32)(x)
    return Activation("relu")(x)

def AttentionUnet(input_shape, wide=False):
    inputs = Input(input_shape, name = "input")

    ker = "he_uniform"
    channels = [16, 32, 64, 128, 256]

    # Block 1
    x = cba_block(inputs, 32)
    block_1_out = cba_block(x, 32)
    pool1 = MaxPooling2D(pool_size=(2, 2), name="block12_pool")(block_1_out)

    # Block 2
    x = cba_block(pool1, 64)
    block_2_out = cba_block(x, 64)
    pool2 = MaxPooling2D(pool_size=(2, 2), name="block23_pool")(block_2_out)

    # Block 3
    x = cba_block(pool2, 128)
    block_3_out = cba_block(x, 128)
    pool3 = MaxPooling2D(pool_size=(2, 2), name="block34_pool")(block_3_out)

    # Block 4
    x = cba_block(pool3, 256)
    x = cba_block(x, 256)
    x = cba_block(x, 256)
    block_4_out = Dropout(0.1)(x)

    # UP2
    x = Conv2DTranspose(128, (2, 2), strides=(2, 2), padding="same", activation="relu", name="upsample2")
    x = concatenate([x, block_3_out], name = "up2_concatenate")
    x = cba_block(x, 256)
    x = cba_block(x, 256)

    # UP3
    x = Conv2DTranspose(64, (2, 2), strides=(2, 2), padding="same", activation="relu", name="upsample3")
    x = concatenate([x, block_2_out], name = "up3_concatenate")
    x = cba_block(x, 128)
    x = cba_block(x, 128)

    # UP4
    x = Conv2DTranspose(32, (2, 2), strides=(2, 2), padding="same", activation="relu", name="upsample4")
```



```

x = concatenate([x, block_1_out], name = "up4_concatenate")
x = cba_block(x, 64)
x = cba_block(x, 64)

outputs = Conv2D(1, (1, 1), activation="sigmoid", kernel_initializer=ker, padding="same", name="")

model = Model(inputs=[inputs], outputs=[outputs], name="Attention-Unet")

return model

```

```

In [22]: def dice_coef(y_true, y_pred):
    smooth = 1
    y_true_f = K.flatten(y_true)
    y_pred_f = K.flatten(y_pred)
    intersection = K.sum(y_true_f * y_pred_f)
    return (2. * intersection + smooth) / (K.sum(y_true_f) + K.sum(y_pred_f) + smooth)

def dice_coef_loss(y_true, y_pred):
    return 1.0 - dice_coef(y_true, y_pred)

def bce_dice_loss(y_true, y_pred):
    return binary_crossentropy(y_true, y_pred) + dice_coef_loss(y_true, y_pred)

def bce_logdice_loss(y_true, y_pred):
    return binary_crossentropy(y_true, y_pred) - K.log(1. - dice_coef_loss(y_true, y_pred))

```

```

In [34]: class SuperTrackingModel:
    def __init__(self, cfg):
        self.cfg = cfg

        self.out_path = cfg.out_path
        self.downscale = cfg.downscale
        self.stack_s = cfg.stack_size
        self.batch_s = cfg.batch_size

        self.model = AttentionUnet(input_shape=cfg.input_shape)

    def load(self, name: str = "base"):
        name_to_id_dict = {
            'base': '13vJzaI0dPldqXz9W3RYH1av_TSXCPBMF'
        }
        output = f'{name}.h5'
        gdown.download(f'https://drive.google.com/uc?id={name_to_id_dict[name]}', output, quiet=False)
        self.model.load_weights(f'/kaggle/working/{name}.h5')

    def predict_on_batch(self, batch: np.ndarray) -> np.ndarray:
        return self.model.predict(batch)

    def _predict_prob_on_clip(self, clip: np.ndarray) -> np.ndarray:
        print('doing predictions')
        n_frames = clip.shape[0]
        # --- get stacks ---
        stacks = []
        for i in range(n_frames - self.stack_s + 1):
            stack = clip[i : i + self.stack_s, ...]
            stack = np.squeeze(np.split(stack, self.stack_s, axis=0))
            stack = np.concatenate(stack, axis=-1)
            stacks.append(stack)
        # --- round to batch size ---
        add_stacks = 0
        while len(stacks) % self.batch_s != 0:
            stacks.append(stacks[-1])
            add_stacks += 1
        # --- group into batches ---
        batches = []
        for i in range(len(stacks) // self.batch_s):
            batch = np.stack(stacks[i * self.batch_s : (i + 1) * self.batch_s])
            batches.append(batch)
        stacks.clear()
        # --- perform predictions ---
        predictions = []
        for batch in batches:
            pred = np.squeeze(self.predict_on_batch(batch))
            predictions.append(pred)
        # --- crop back to source length ---
        predictions = np.concatenate(predictions, axis=0)
        if add_stacks > 0:

```

```

        predictions = predictions[:-add_stacks, ...]
    batches.clear()
    # --- add (stack_s - 1) null frames at the beginning ---
    start_frames = np.zeros((self.stack_s - 1, predictions.shape[1], predictions.shape[2]), dtype=
    predictions = np.concatenate((start_frames, predictions), axis=0)
    print('predictions are made')
    return predictions

def get_labels_from_prediction(self, pred_prob: np.ndarray, upscale_coords: bool) -> np.ndarray:
    # todo: get ball coordinates from predicted masks
    # remember to upscale predicted coords if you use downscaled images
    n_frames = pred_prob.shape[0]
    coords = np.zeros([n_frames, 3])

    variance_thres = 1e-4
    for i in range(n_frames):
        x, y = center_of_mass(pred_prob[i])
        ball_code = 1

        if math.isnan(x) and math.isnan(y) or variance(pred_prob[i]) < variance_thres:
            x, y, ball_code = -1, -1, 0

        if upscale_coords:
            x, y = x * 2, y * 2

        coords[i] = [ball_code, round(y), round(x)]
    return coords

# LBL4
def _postprocess_labels(self, labels):
    print('Postprocessing labels')
    frames, x, y = [], [], []
    for i in range(labels.shape[0]):
        if labels[i, 0] == 1:
            frames.append(i)
            x.append(labels[i, 1])
            y.append(labels[i, 2])

    frames_x, frames_y = [0], [0]
    clean_x, clean_y = [0], [0]
    ball_size = 35
    for i in range(len(frames) - 2):
        i += 1
        if min(abs(x[i - 1] - x[i]), abs(x[i + 1] - x[i])) < ball_size:
            frames_x.append(frames[i])
            clean_x.append(x[i])

        if min(abs(y[i - 1] - y[i]), abs(y[i + 1] - y[i])) < ball_size:
            frames_y.append(frames[i])
            clean_y.append(y[i])

    clean_x[0] = clean_x[1]
    clean_y[0] = clean_y[1]
    frames_x.append(labels.shape[0])
    frames_y.append(labels.shape[0])
    clean_x.append(clean_x[-1])
    clean_y.append(clean_y[-1])

    process_x = interp1d(frames_x, clean_x, kind='quadratic')
    process_y = interp1d(frames_y, clean_y, kind='quadratic')

    frames = np.arange(labels.shape[0])
    x = process_x(frames)
    y = process_y(frames)
    new_labels = np.zeros(labels.shape)
    for i in range(labels.shape[0]):
        new_labels[i, 0] = 1
        new_labels[i, 1] = x[i]
        new_labels[i, 2] = y[i]
    return new_labels

def predict(self, clip: np.ndarray, upscale_coords=True) -> np.ndarray:
    prob_pr = self._predict_prob_on_clip(clip)
    labels_pr = self.get_labels_from_prediction(prob_pr, upscale_coords)
    return labels_pr, prob_pr

```

```

def test(self, data_path: Path, games: List[int], do_visualization=False, test_name='test'):
    game_clip_pairs = get_game_clip_pairs(data_path, games)
    SIBATRACC_vals = []
    for game, clip in game_clip_pairs:
        data = load_clip_data(data_path, game, clip, downscale=self.downscale)
        if do_visualization:
            data_full = load_clip_data(data_path, game, clip, downscale=False) if self.downscale
            labels_gt = load_clip_labels(data_path, game, clip, downscale=False)
            labels_pr, prob_pr = self.predict(data)
            labels_pr = self._postprocess_labels(labels_pr)
            SIBATRACC_per_frame, SIBATRACC_total = Metrics.evaluate_predictions(labels_gt, labels_pr)
            SIBATRACC_vals.append(SIBATRACC_total)
        if do_visualization:
            visualize_prediction(data_full, labels_pr, self.out_path, f'{test_name}_g{game}_c{cl
            visualize_prob(data, prob_pr, self.out_path, f'{test_name}_g{game}_c{clip}')
            del data_full
        del data, labels_gt, labels_pr, prob_pr
        gc.collect()
    SIBATRACC_final = sum(SIBATRACC_vals) / len(SIBATRACC_vals)
    return SIBATRACC_final

```

```

def train(self, train_gen, val_gen):

```

```

    # LBL2
    checkpoint = keras.callbacks.ModelCheckpoint(
        self.cfg.save_path,
        monitor='val_loss',
        verbose=0,
        save_best_only=True,
        save_weights_only=True,
        mode='auto',
        period=1
    )

    boundaries = [100 * 25]
    values = [1e-4, 1e-5]
    lr_schedule = PiecewiseConstantDecay(boundaries, values)

    self.model.compile(
        optimizer=Adam(learning_rate=lr_schedule, decay=1e-4),
        loss=dice_coef_loss,
        metrics=[dice_coef]
    )

    # LBL1, LBL2, LBL3, LBL5
    self.model.fit_generator(
        train_gen.random_g(self.batch_s),
        steps_per_epoch=100,
        epochs=50,
        verbose=1,
        callbacks=[checkpoint],
        validation_data=val_gen.random_g(self.batch_s),
        validation_steps=50
    )

```

In [35]: # hyperparameters

```

cfg_dict = {
    "out_path": prepare_experiment(Path('/kaggle/working')),
    "save_path": "/kaggle/working/weights_final.h5",
    "batch_size": 4,
    "stack_size": 3,
    "downscale": True,
    "input_shape": (360, 640, 9)
}

```

```

cfg = namedtuple("Config", cfg_dict.keys())(**cfg_dict)

```

```

In [11]: train_gen = DataGenerator(
    Path('../input/tennistackingassignment/train/'),
    games=[1, 2, 3, 4],
    stack_s=cfg.stack_size,
    downscale=cfg.downscale,
    pool_s=10, pool_update_s=4,
    quiet=True
)

```

```

val_gen = DataGenerator(

```

```

    Path('../input/tennistackingassignment/train/'),
    games=[5, 6],
    stack_s=cfg.stack_size,
    downscale=cfg.downscale,
    pool_s=4, pool_update_s=2,
    quiet=True
)

```

Пример пайплайна для обучения модели:

```

In [16]: model = SuperTrackingModel(cfg)
         model.train(train_gen, val_gen)

```

```

Epoch 1/50
100/100 [=====] - 30s 288ms/step - loss: 0.9909 - dice_coef: 0.0091 - val_loss:
0.9958 - val_dice_coef: 0.0042
Epoch 2/50
100/100 [=====] - 28s 278ms/step - loss: 0.9765 - dice_coef: 0.0235 - val_loss:
0.9907 - val_dice_coef: 0.0093
Epoch 3/50
100/100 [=====] - 28s 280ms/step - loss: 0.9651 - dice_coef: 0.0349 - val_loss:
0.9849 - val_dice_coef: 0.0151
Epoch 4/50
100/100 [=====] - 31s 310ms/step - loss: 0.9407 - dice_coef: 0.0593 - val_loss:
0.9862 - val_dice_coef: 0.0138
Epoch 5/50
100/100 [=====] - 33s 332ms/step - loss: 0.9016 - dice_coef: 0.0984 - val_loss:
0.9679 - val_dice_coef: 0.0321
Epoch 6/50
100/100 [=====] - 28s 279ms/step - loss: 0.8376 - dice_coef: 0.1624 - val_loss:
0.9268 - val_dice_coef: 0.0732
Epoch 7/50
100/100 [=====] - 28s 280ms/step - loss: 0.7463 - dice_coef: 0.2537 - val_loss:
0.9116 - val_dice_coef: 0.0884
Epoch 8/50
100/100 [=====] - 41s 409ms/step - loss: 0.7075 - dice_coef: 0.2925 - val_loss:
0.8744 - val_dice_coef: 0.1256
Epoch 9/50
100/100 [=====] - 28s 279ms/step - loss: 0.6962 - dice_coef: 0.3038 - val_loss:
0.7877 - val_dice_coef: 0.2123
Epoch 10/50
100/100 [=====] - 28s 281ms/step - loss: 0.6197 - dice_coef: 0.3803 - val_loss:
0.7401 - val_dice_coef: 0.2599
Epoch 11/50
100/100 [=====] - 28s 280ms/step - loss: 0.5675 - dice_coef: 0.4325 - val_loss:
0.7453 - val_dice_coef: 0.2547
Epoch 12/50
100/100 [=====] - 41s 411ms/step - loss: 0.5726 - dice_coef: 0.4274 - val_loss:
0.8034 - val_dice_coef: 0.1966
Epoch 13/50
100/100 [=====] - 28s 282ms/step - loss: 0.5485 - dice_coef: 0.4515 - val_loss:
0.6054 - val_dice_coef: 0.3946
Epoch 14/50
100/100 [=====] - 28s 279ms/step - loss: 0.5518 - dice_coef: 0.4482 - val_loss:
0.6492 - val_dice_coef: 0.3508
Epoch 15/50
100/100 [=====] - 28s 281ms/step - loss: 0.5283 - dice_coef: 0.4717 - val_loss:
0.6063 - val_dice_coef: 0.3937
Epoch 16/50
100/100 [=====] - 30s 305ms/step - loss: 0.5273 - dice_coef: 0.4727 - val_loss:
0.6595 - val_dice_coef: 0.3405
Epoch 17/50
100/100 [=====] - 28s 281ms/step - loss: 0.5121 - dice_coef: 0.4879 - val_loss:
0.5912 - val_dice_coef: 0.4088
Epoch 18/50
100/100 [=====] - 37s 372ms/step - loss: 0.5040 - dice_coef: 0.4960 - val_loss:
0.6314 - val_dice_coef: 0.3686
Epoch 19/50
100/100 [=====] - 28s 281ms/step - loss: 0.5016 - dice_coef: 0.4984 - val_loss:
0.5464 - val_dice_coef: 0.4536
Epoch 20/50
100/100 [=====] - 30s 303ms/step - loss: 0.4776 - dice_coef: 0.5224 - val_loss:
0.5382 - val_dice_coef: 0.4618
Epoch 21/50
100/100 [=====] - 28s 278ms/step - loss: 0.4664 - dice_coef: 0.5336 - val_loss:
0.5074 - val_dice_coef: 0.4926
Epoch 22/50
100/100 [=====] - 28s 282ms/step - loss: 0.4639 - dice_coef: 0.5361 - val_loss:
0.5764 - val_dice_coef: 0.4226

```

0.5764 - val_dice_coef: 0.4236
Epoch 23/50
100/100 [=====] - 39s 390ms/step - loss: 0.4616 - dice_coef: 0.5384 - val_loss:
0.6223 - val_dice_coef: 0.3777
Epoch 24/50
100/100 [=====] - 28s 280ms/step - loss: 0.4688 - dice_coef: 0.5312 - val_loss:
0.5825 - val_dice_coef: 0.4175
Epoch 25/50
100/100 [=====] - 28s 281ms/step - loss: 0.4597 - dice_coef: 0.5403 - val_loss:
0.6624 - val_dice_coef: 0.3376
Epoch 26/50
100/100 [=====] - 28s 280ms/step - loss: 0.4497 - dice_coef: 0.5503 - val_loss:
0.5458 - val_dice_coef: 0.4542
Epoch 27/50
100/100 [=====] - 40s 406ms/step - loss: 0.4556 - dice_coef: 0.5444 - val_loss:
0.5658 - val_dice_coef: 0.4342
Epoch 28/50
100/100 [=====] - 28s 279ms/step - loss: 0.4517 - dice_coef: 0.5483 - val_loss:
0.5513 - val_dice_coef: 0.4487
Epoch 29/50
100/100 [=====] - 28s 284ms/step - loss: 0.4629 - dice_coef: 0.5371 - val_loss:
0.5301 - val_dice_coef: 0.4699
Epoch 30/50
100/100 [=====] - 32s 322ms/step - loss: 0.4559 - dice_coef: 0.5441 - val_loss:
0.5350 - val_dice_coef: 0.4650
Epoch 31/50
100/100 [=====] - 28s 279ms/step - loss: 0.4662 - dice_coef: 0.5338 - val_loss:
0.5362 - val_dice_coef: 0.4638
Epoch 32/50
100/100 [=====] - 28s 281ms/step - loss: 0.4607 - dice_coef: 0.5393 - val_loss:
0.5408 - val_dice_coef: 0.4592
Epoch 33/50
100/100 [=====] - 28s 282ms/step - loss: 0.4493 - dice_coef: 0.5507 - val_loss:
0.5329 - val_dice_coef: 0.4671
Epoch 34/50
100/100 [=====] - 28s 284ms/step - loss: 0.4455 - dice_coef: 0.5545 - val_loss:
0.5277 - val_dice_coef: 0.4723
Epoch 35/50
100/100 [=====] - 35s 350ms/step - loss: 0.4542 - dice_coef: 0.5458 - val_loss:
0.5566 - val_dice_coef: 0.4434
Epoch 36/50
100/100 [=====] - 28s 284ms/step - loss: 0.4598 - dice_coef: 0.5402 - val_loss:
0.5290 - val_dice_coef: 0.4710
Epoch 37/50
100/100 [=====] - 28s 278ms/step - loss: 0.4460 - dice_coef: 0.5540 - val_loss:
0.5220 - val_dice_coef: 0.4780
Epoch 38/50
100/100 [=====] - 28s 282ms/step - loss: 0.4540 - dice_coef: 0.5460 - val_loss:
0.5054 - val_dice_coef: 0.4946
Epoch 39/50
100/100 [=====] - 36s 366ms/step - loss: 0.4471 - dice_coef: 0.5529 - val_loss:
0.5039 - val_dice_coef: 0.4961
Epoch 40/50
100/100 [=====] - 28s 284ms/step - loss: 0.4439 - dice_coef: 0.5561 - val_loss:
0.5071 - val_dice_coef: 0.4929
Epoch 41/50
100/100 [=====] - 28s 282ms/step - loss: 0.4582 - dice_coef: 0.5418 - val_loss:
0.5313 - val_dice_coef: 0.4687
Epoch 42/50
100/100 [=====] - 28s 283ms/step - loss: 0.4452 - dice_coef: 0.5548 - val_loss:
0.5220 - val_dice_coef: 0.4780
Epoch 43/50
100/100 [=====] - 37s 373ms/step - loss: 0.4451 - dice_coef: 0.5549 - val_loss:
0.5337 - val_dice_coef: 0.4663
Epoch 44/50
100/100 [=====] - 33s 336ms/step - loss: 0.4576 - dice_coef: 0.5424 - val_loss:
0.5082 - val_dice_coef: 0.4918
Epoch 45/50
100/100 [=====] - 28s 281ms/step - loss: 0.4433 - dice_coef: 0.5567 - val_loss:
0.5263 - val_dice_coef: 0.4737
Epoch 46/50
100/100 [=====] - 28s 279ms/step - loss: 0.4459 - dice_coef: 0.5541 - val_loss:
0.5321 - val_dice_coef: 0.4679
Epoch 47/50
100/100 [=====] - 28s 281ms/step - loss: 0.4361 - dice_coef: 0.5639 - val_loss:
0.5298 - val_dice_coef: 0.4702
Epoch 48/50
100/100 [=====] - 28s 280ms/step - loss: 0.4371 - dice_coef: 0.5633 - val_loss:
0.5298 - val_dice_coef: 0.4702

```
100/100 [=====] - 28s 282ms/step - loss: 0.4371 - dice_coef: 0.5629 - val_loss:
0.5164 - val_dice_coef: 0.4836
Epoch 49/50
100/100 [=====] - 33s 327ms/step - loss: 0.4454 - dice_coef: 0.5546 - val_loss:
0.5343 - val_dice_coef: 0.4657
Epoch 50/50
100/100 [=====] - 28s 279ms/step - loss: 0.4379 - dice_coef: 0.5621 - val_loss:
0.5026 - val_dice_coef: 0.4974
In [36]: model = SuperTrackingModel(cfg)
         model.load()
```

```
Downloading...
From: https://drive.google.com/uc?id=13vJzaI0dPldqXz9W3RYHlav_TSXCPBMF
To: /kaggle/working/base.h5
100%|██████████| 14.3M/14.3M [00:00<00:00, 275MB/s]
```

```
In [37]: model.test(
         Path('../input/tennistackingassignment/test/'),
         games=[1, 2],
         do_visualization=False,
         test_name='test'
         )
```

```
loading clip data (game 1, clip 1) downscaled
loading clip labels (game 1, clip 1)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 1, clip 2) downscaled
loading clip labels (game 1, clip 2)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 1, clip 3) downscaled
loading clip labels (game 1, clip 3)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 1, clip 4) downscaled
loading clip labels (game 1, clip 4)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 1, clip 5) downscaled
loading clip labels (game 1, clip 5)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 1, clip 6) downscaled
loading clip labels (game 1, clip 6)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 1, clip 7) downscaled
loading clip labels (game 1, clip 7)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 1, clip 8) downscaled
loading clip labels (game 1, clip 8)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 2, clip 1) downscaled
loading clip labels (game 2, clip 1)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 2, clip 2) downscaled
loading clip labels (game 2, clip 2)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 2, clip 3) downscaled
loading clip labels (game 2, clip 3)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 2, clip 4) downscaled
```

```

loading clip data (game 2, clip 4) downscaled
loading clip labels (game 2, clip 4)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 2, clip 5) downscaled
loading clip labels (game 2, clip 5)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 2, clip 6) downscaled
loading clip labels (game 2, clip 6)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 2, clip 7) downscaled
loading clip labels (game 2, clip 7)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 2, clip 8) downscaled
loading clip labels (game 2, clip 8)
doing predictions
predictions are made
Postprocessing labels
loading clip data (game 2, clip 9) downscaled
loading clip labels (game 2, clip 9)
doing predictions
predictions are made
Postprocessing labels

```

Out[37]:0.6071705397088758

Пример пайплайна для тестирования обученной модели:

```

In [38]: cfg_dict = {
    "out_path": prepare_experiment(Path('/kaggle/working')),
    "save_path": "/kaggle/working/weights_final.h5",
    "batch_size": 4,
    "stack_size": 3,
    "downscale": True,
    "input_shape": (360, 640, 9)
}

cfg = namedtuple("Config", cfg_dict.keys())(**cfg_dict)

new_model = SuperTrackingModel(cfg)
new_model.load()
sibatracc_final = new_model.test(
    Path('../input/tennisttrackingassignment/test/'),
    games=[1,],
    do_visualization=True,
    test_name='test'
)

print(f'SiBaTrAcc final value: {sibatracc_final}')

```

```

Downloading...
From: https://drive.google.com/uc?id=13vJzaI0dPldqXz9W3RYHlav_TSXCPBMF
To: /kaggle/working/base.h5
100%|██████████| 14.3M/14.3M [00:00<00:00, 287MB/s]
loading clip data (game 1, clip 1) downscaled
loading clip data (game 1, clip 1)
loading clip labels (game 1, clip 1)
doing predictions
predictions are made
Postprocessing labels
performing clip visualization
loading clip data (game 1, clip 2) downscaled
loading clip data (game 1, clip 2)
loading clip labels (game 1, clip 2)
doing predictions
predictions are made
Postprocessing labels
performing clip visualization
loading clip data (game 1, clip 3) downscaled
loading clip data (game 1, clip 3)
loading clip labels (game 1, clip 3)
doing predictions
predictions are made
Postprocessing labels
performing clip visualization
loading clip data (game 1, clip 4) downscaled
loading clip data (game 1, clip 4)
loading clip labels (game 1, clip 4)
doing predictions
predictions are made
Postprocessing labels
performing clip visualization
loading clip data (game 1, clip 5) downscaled
loading clip data (game 1, clip 5)
loading clip labels (game 1, clip 5)
doing predictions
predictions are made
Postprocessing labels
performing clip visualization
loading clip data (game 1, clip 6) downscaled
loading clip data (game 1, clip 6)
loading clip labels (game 1, clip 6)
doing predictions
predictions are made
Postprocessing labels
performing clip visualization
loading clip data (game 1, clip 7) downscaled
loading clip data (game 1, clip 7)
loading clip labels (game 1, clip 7)
doing predictions
predictions are made
Postprocessing labels
performing clip visualization
loading clip data (game 1, clip 8) downscaled
loading clip data (game 1, clip 8)
loading clip labels (game 1, clip 8)
doing predictions
predictions are made
Postprocessing labels
performing clip visualization
SiBaTrAcc final value: 0.7271107727496607

```

Во время самостоятельного тестирования попробуйте хотя бы раз сделать тестирование с визуализацией (`do_visualization=True`), чтобы визуально оценить качество трекинга разработанной моделью.

Загрузка модели через функцию `load` должна происходить полностью автоматически без каких-либо действий со стороны пользователя! Один из вариантов подобной реализации с использованием google drive и пакета `gdown` приведен в разделе с дополнениями.

Дополнения

Иногда при записи большого количества файлов в output директорию kaggle может "тупить" и не отображать корректно структуру дерева файлов в output и не показывать кнопки для скачивания выбранного файла. В этом случае удобно будет запаковать директорию с экспериментом и выкачать ее вручную. Пример для выкачивания директории с первым экспериментом приведен ниже:

```
In [ ]: %cd /kaggle/working/
```



```
!zip -r "exp_1.zip" "exp_1"
from IPython.display import FileLink
FileLink(r'exp_1.zip')
```

удалить лишние директории или файлы в output тоже легко:

```
In[: !rm -r /kaggle/working/exp_1
```

Для реализации загрузки данных рекомендуется использовать облачное хранилище google drive и пакет gdown для скачивания файлов. Пример подобного использования приведен ниже:

1. загружаем файл в google drive (в данном случае, это npz архив, содержащий один numpy массив по ключу 'w')
2. в интерфейсе google drive открываем доступ на чтение к файлу по ссылке и извлекаем из ссылки id файла
3. формируем url для скачивания файла
4. с помощью gdown скачиваем файл
5. распаковываем npz архив и пользуемся numpy массивом

Обратите внимание, что для корректной работы нужно правильно определить id файла. В частности, в ссылке https://drive.google.com/file/d/1kZ8CC-zfkB_TlwtBjuPcEfsPV0Jz7IPA/view?usp=sharing id файла заключен между ...d/ и /view?... и равен 1kZ8CC-zfkB_TlwtBjuPcEfsPV0Jz7IPA

```
In[: id = '1kZ8CC-zfkB_TlwtBjuPcEfsPV0Jz7IPA'
      url = f'https://drive.google.com/uc?id={id}'
      output = 'sample-weights.npz'
      gdown.download(url, output, quiet=False)

import numpy as np

weights = np.load('/kaggle/working/sample-weights.npz')['w']
print(weights)
```